

SINOPSIS SKRIPSI

Perbandingan Vector Retrieval, BM25, dan Hybrid Retrieval pada Sistem Tanya Jawab Multi-Dokumen Berbasis Retrieval Augmented Generation (RAG)

Nama: Nuno Tamada Jackson Jacob

NIM: 211505144

1. Latar Belakang

Kebutuhan untuk mendapatkan jawaban yang akurat dari banyak dokumen semakin meningkat seiring bertambahnya volume informasi digital. Model bahasa besar (Large Language Model/LLM) memiliki kemampuan memahami dan menghasilkan teks, namun cenderung memberikan jawaban yang tidak selalu terikat pada sumber yang jelas. Pendekatan Retrieval Augmented Generation (RAG) menjadi solusi dengan cara mencari potongan dokumen yang relevan terlebih dahulu, kemudian menyusun jawaban berdasarkan konteks yang ditemukan.

Kualitas sistem RAG sangat bergantung pada metode retrieval. Vector retrieval unggul pada pencarian semantik dan parafrase, BM25 unggul pada kecocokan kata kunci secara leksikal, sedangkan Hybrid Retrieval menggabungkan keduanya. Meskipun Hybrid sering diasumsikan lebih baik, klaim tersebut perlu dibuktikan secara empiris pada corpus dan pertanyaan evaluasi yang sama. Oleh karena itu, penelitian ini berfokus pada perbandingan Vector, BM25, dan Hybrid retrieval dalam pipeline RAG multi-dokumen berbahasa Indonesia.

2. Rumusan Masalah

- Bagaimana merancang sistem tanya jawab multi-dokumen berbasis RAG yang dapat digunakan untuk membandingkan metode retrieval?
- Bagaimana perbandingan performa Vector, BM25, dan Hybrid retrieval pada corpus dan golden set yang sama?
- Bagaimana pengaruh nilai top-K dan bobot Hybrid terhadap kualitas retrieval?

3. Tujuan Penelitian

- Membangun sistem tanya jawab multi-dokumen berbasis RAG yang dilengkapi sitasi sumber dan modul evaluasi retrieval.
- Membandingkan performa Vector, BM25, dan Hybrid retrieval secara empiris menggunakan metrik Success@K, Precision@K, MRR, dan latency.
- Menganalisis pengaruh nilai top-K dan bobot Hybrid untuk menentukan konfigurasi retrieval yang lebih baik pada corpus penelitian.

4. Batasan Penelitian

- Fokus evaluasi utama berada pada tahap retrieval, bukan penilaian penuh kualitas bahasa jawaban LLM.
- Corpus penelitian menggunakan dokumen berbahasa Indonesia berlisensi terbuka, antara lain subset peraturan/regulasi publik.
- Format dokumen yang diuji meliputi teks, Markdown, dan PDF berbasis teks.
- Bobot Hybrid awal bersifat heuristik dan selanjutnya diuji melalui eksperimen sensitivitas.

5. Metodologi Penelitian

- Studi literatur mengenai RAG, embedding, BM25, dan Hybrid retrieval.
- Pembangunan sistem mencakup ingest dokumen, chunking, embedding, retrieval, generasi jawaban, sitasi, serta modul evaluasi.
- Penyusunan corpus sekitar 20–40 dokumen dan golden set sekitar 40–60 pertanyaan, termasuk pertanyaan yang tidak memiliki jawaban pada corpus.
- Pelaksanaan eksperimen: perbandingan Vector, BM25, dan Hybrid; pengujian $K = 3, 5$, dan 10 ; serta pengujian beberapa konfigurasi bobot Hybrid.
- Evaluasi menggunakan $\text{Success}@K$ (document-level hit), $\text{Precision}@K$, Mean Reciprocal Rank (MRR), dan latency retrieval.
- Analisis hasil eksperimen dan penarikan kesimpulan.

6. Hasil yang Diharapkan

Penelitian ini diharapkan menghasilkan prototipe sistem tanya jawab multi-dokumen berbasis RAG serta temuan empiris mengenai metode retrieval terbaik pada corpus yang digunakan. Hasil tersebut dapat menjadi dasar pemilihan strategi retrieval yang terukur, bukan sekadar asumsi bahwa Hybrid selalu lebih unggul.

7. Kontribusi Penelitian

Kontribusi utama penelitian adalah perbandingan empiris Vector, BM25, dan Hybrid retrieval pada pipeline RAG multi-dokumen, dilengkapi analisis pengaruh top-K dan bobot Hybrid. Implementasi sistem berfungsi sebagai sarana eksperimen dan demonstrasi, sedangkan fokus ilmiah diarahkan pada evaluasi metode retrieval.